Почему исполнительную часть VLA-политики можно обучить только обучением с подкреплением: математическое обоснование поэтапного бутстрэппинга

Д. Нуртдинов

Черновик теоретической главы диссертации

4 ноября 2026 г.

Аннотация

Рассматривается адаптация предобученной модели «зрение–язык–действие» (VLA, здесь SmolVLA) к новой кинематической структуре (тросовый параллельный робот CDPR, манипулятор WidowX-200), при которой визуально-языковая часть заморожена, а обучается только исполнительная часть (остаточная голова действий) консервативными методами PPO/GRPO с усечением отношения правдоподобий. Ставится вопрос: почему такое обучение вообще возможно и приводит к успешному выполнению инструкций манипуляции. Ответ дан в виде системы утверждений с доказательствами. (1) При бинарной награде GRPO в среднем поднимается по монотонному преобразованию $2\arcsin\sqrt{p}$ вероятности успеха, поэтому оптимизируется сама метрика задачи. (2) Для вероятности успеха на конечном горизонте получена оценка улучшения в доверительной области и оценка сохранения навыков; из неё следуют условия, при которых навык не забывается, и объяснение накопленного дрейфа. (3) Последовательность консервативных шагов трактуется как неточный зеркальный спуск в пространстве политик, который сходится к лучшей политике, представимой на замороженных признаках, со скоростью $O(\sqrt{HD/K})$. Здесь D есть KL-расстояние от начальной политики до успешной. (4) При разреженной награде сигнал отсутствует, пока вероятность успеха равна нулю, а для составной задачи она экспоненциально мала по числу этапов. Простые навыки, плотная награда, лестница стартовых распределений и композиция под одной инструкцией образуют конструктивный способ сделать её отделённой от нуля за полиномиальную цену. Сводная теорема объединяет эти утверждения. В ней точно определено, какую роль в оценках играли бы демонстрации и чем пайплайн их заменяет. Все неравенства проверены численно на точно решаемых конечных марковских процессах (приложение A).

Содержание

1 Введение и постановка вопроса **2**

2 Математическая модель **3**

2.1 Контексты, состояния и история 3

2.2 Спецификация навыка 4

2.3 Класс политик и параметризация 4

2.4 Функции ценности и распределения 4

2.5 Алгоритм (идеализация GRPO) 5

3 Вспомогательные утверждения **5**

4 Что оптимизирует GRPO при бинарной награде **6**

5 Устойчивость: доверительная область и сохранение навыков 7

6 Сходимость: консервативные шаги как неточный зеркальный спуск 9

7 Сигнал при разреженной награде и роль простых навыков 11

8 Сводная теорема: ответ на вопрос 14

9 Связь с экспериментами и проверяемые предсказания 16

10 Границы применимости 17

11 Проект положений, выносимых на защиту 18

A Численная проверка утверждений 18

1 Введение и постановка вопроса

Эмпирическая основа. В эксперименте на тросовом роботе (CDPR) остаточный контроллер над замороженным SmolVLA достиг 69,14 % строгого успеха полной задачи *put* ⟨*object*⟩ *into* ⟨*destination*⟩ (1416 из 2048 попыток вне валидационной панели). Каждая попытка начиналась с пустого захвата и выполнялась без учителя. Поэтапный пайплайн на WidowX-200 воспроизводит ту же схему на другой кинематике: сначала простые навыки (подход, захват, размещение), затем их композиция под одной инструкцией.

Вопрос. *Почему исполнительную часть VLA-политики (action expert / actor / action head) можно обучить, используя только алгоритмы обучения с подкреплением с консервативными, слабо изменяющими политику обновлениями (PPO, GRPO с усечением), и почему это обучение приводит к успеху на инструкциях манипуляции объектами?*

Вопрос нетривиален по четырём причинам.

(i) **Разреженность.** Награда бинарна: успех или неуспех. Пока успехов нет, градиент политики тождественно равен нулю (лемма 7.1).

(ii) **Длинный горизонт и контакт.** Успех требует цепочки точных событий: подход, захват, подъём, перенос, отпускание. Вероятность случайно пройти цепочку экспоненциально мала по её длине (предложение 7.2).

(iii) **Одна политика, много инструкций.** Параметры общие, поэтому улучшение одного навыка может разрушать другой. Это наблюдалось многократно (раздел 9).

(iv) **Новая кинематика.** Предобученные знания о действиях почти не переносятся: на CDPR замороженный SmolVLA-приор действует как постоянное смещение, а всё поведение задаёт остаточная голова. Поэтому из предобучения в задачу переносится прежде всего *представление*, а не поведение.

Что именно означает «только RL». Чтобы утверждение было математическим, а не риторическим, зафиксируем информационную модель.

Определение 1.1 (Информационная модель обучения)**.** Обучающийся имеет доступ (а) к замороженному предобученному отображению признаков φ (визуально-языковой бэкбон, проекция, приор действий); (б) к симулятору со сбросом в стартовые распределения из спецификации навыков (определение 2.1); (в) к предикатам успеха этих навыков. Обучающийся

не получает целевых действий из внешнего источника: от человека, скриптового оракула или контроллера-помощника. Повторное использование данных, порождённых самой политикой (самоимитация на собственных успехах, переразметка инструкций), допускается: действия в этих данных выбраны обучающимся, а отобраны предикатом успеха.

В этой модели «описать простейшие навыки» означает задать для каждого навыка тройку (инструкция, стартовое распределение, предикат успеха). Ниже показано, что через эти три объекта и замороженное представление выражаются все величины в оценках сходимости.

Структура ответа. Ответ разбивается на четыре условия; каждому соответствует группа утверждений.

Подвопрос	Результат
(У1) Что оптимизирует GRPO?	Теорема 4.1: монотонное преобразование вероятности успеха; следствие 4.2: Парето-оптимальность.
(У2) Почему консервативный шаг не вредит?	Теорема 5.1 (улучшение), теорема 5.4 (сохранение навыков), следствия 5.5–5.8.
(У3) Почему последовательность шагов приходит к успеху?	Теоремы 6.2 и 6.4: неточный зеркальный спуск; предложение 6.6: потолок представления.
(У4) Откуда берётся сигнал и зачем простые навыки?	Лемма 7.1, предложения 7.2, 7.3, теоремы 7.4, 7.5, предложение 7.6.
Ответ целиком	Теорема 8.1 и предложение 8.2.

Стандартные результаты, на которые опирается глава, явно атрибутированы (раздел 10). Собственный вклад составляют их формулировка для вероятности успеха на конечном горизонте с явными константами, следствия о сохранении навыков и якоре, теорема о лестнице стартов, теорема о композиции с членами переноса инструкции и рассогласования передачи, нижняя граница навыков при сбалансированной самоимитации и сводная теорема.

2 Математическая модель

2.1 Контексты, состояния и история

Пусть $\mathcal{L}$ — конечное множество инструкций, Ξ — пространство сцен (объекты, их положения, приёмник). Контекст $c = (\ell, \xi)$ распределён по закону $\mathcal{D}$. Физическое состояние симулятора $s \in S$; наблюдение o_h (изображения камер и проприоцепция) порождается из s_h. Решения принимаются в моменты $h = 0, \dots, H-1$. Одно решение — это кусок действий (action chunk), из которого исполняется префикс, после чего политика заново наблюдает сцену. Поэтому H считает *решения*, а не шаги физики; в экспериментах CDPR H порядка 40–128.

Замороженный SmolVLA выдаёт приор действий p_h по наблюдению. Он может быть случайным (в нём собственный шум сэмплирования), но его закон не зависит от обучаемых параметров. Поэтому приор относится к *окружению* как часть канала наблюдения.

Обозначим через $u_h \in \mathbb{R}^m$ латентное (до усечения) действие и через $T(\cdot \mid s, u)$ переходное ядро. В него входят усечение $a = \mathrm{clip}(u, -1, 1)$, низкоуровневый контроллер (для CDPR — обратная кинематика тросов) и физика. *Расширенное состояние*

$$z_h = (c,\ s_{0:h},\ o_{0:h},\ p_{0:h},\ u_{0:h-1}) \in \mathcal{Z}_h$$

содержит всю историю. При любой политике, зависящей от истории, процесс (z_h) марковский; z_H есть вся траектория. Все утверждения ниже формулируются для этого процесса. Частичная наблюдаемость учтена тем, что класс политик ограничен (п. 2.3), а не тем, что политика видит s_h.

2.2 Спецификация навыка

Определение 2.1 (Навык и составная задача)**.** *Навык* (задача) $\mathcal{T} = (\ell, \mu, E, H)$ состоит из инструкции ℓ, стартового распределения μ на парах (сцена, начальное состояние), измеримого *события успеха* $E \subseteq \mathcal{Z}_H$ и горизонта H. Вероятность успеха политики π:

$$J_{\mathcal{T}}(\pi) = \mathbb{P}^{\pi}_{\mu}(z_H \in E).$$

Составная задача $\mathcal{T}_c = (\ell_c, \mu_c, E_c, H)$ — задача, чей успех требует последовательного выполнения этапов. *Вехи* $E^{(1)} \supseteq E^{(2)} \supseteq \cdots \supseteq E^{(m)} = E_c$ — вложенные события «этапы $1, \ldots, j$ выполнены».

Примеры из пайплайна: *move to* $\langle o \rangle$ (подход с пустым захватом), *pick up* $\langle o \rangle$ (стартовое распределение может включать «выровненный захват» над объектом), *put* $\langle o \rangle$ *into bowl* со стартами «объект уже в захвате» (caught starts), и составная задача с пустым захватом в начале.

2.3 Класс политик и параметризация

Допущение 2.2 (Стационарное представление)**.** Существует фиксированное (не зависящее от обучаемых параметров) измеримое отображение $\varphi_h : \mathcal{Z}_h \to \mathbb{R}^n$, $x_h = \varphi_h(z_h)$. Оно включает случайную проекцию визуальных токенов, проприоцепцию, приор p_h и инструкцию. Класс допустимых политик:

$$\Pi_{\varphi} = \big\{\pi = (\pi_h)_{h<H} : \ \pi_h(\cdot \mid z) \text{ зависит от } z \text{ только через } \varphi_h(z)\big\}.$$

Допущение выполняется буквально, когда бэкбон, LoRA и проекция заморожены, как на этапе полной задачи в CDPR. Существенно, что *сравнительная* политика в оценках тоже берётся из Π_{φ}: никакой привилегированной информации у неё нет.

Реализованная параметризация (CDPR; для WidowX аналогично):

$$\mu_\theta(x) = \tanh\big(p + s_r \tanh f_\theta(x)\big), \qquad u_h \sim \mathcal{N}\big(\mu_\theta(x_h) + b_h,\ \operatorname{diag}\sigma_\theta^2\big), \qquad a_h = \operatorname{clip}(u_h, -1, 1), \tag{1}$$

где f_θ — остаточная сеть, s_r — масштаб остатка, b_h — экзогенное смещение эпизода. Действием в смысле теории считается латентное u_h, а усечение отнесено к окружению. Тогда политика имеет полный носитель, и все KL-расстояния ниже конечны. Это согласуется с реализацией, где правдоподобие вычисляется для сохранённого u_h при сохранённом b_h.

2.4 Функции ценности и распределения

Для политики π и задачи $\mathcal{T}$ положим

$$V^{\pi}_h(z) = \mathbb{P}^{\pi}(E \mid z_h = z), \quad Q^{\pi}_h(z,u) = \mathbb{P}^{\pi}(E \mid z_h = z, u_h = u), \quad A^{\pi}_h = Q^{\pi}_h - V^{\pi}_h,$$

так что $V^{\pi}_H(z) = \mathbf{1}\{z \in E\}$ для всех π и $Q, V \in [0,1]$. Через d^{π}_h обозначим закон z_h при π. Для пары политик π, π' введём

$$\alpha_h(z) = \mathrm{TV}\big(\pi'_h(\cdot \mid z), \pi_h(\cdot \mid z)\big), \qquad \bar{\alpha}_h = \mathbb{E}_{z \sim d^{\pi}_h} \alpha_h(z), \qquad \bar{A}_h(z) = \mathbb{E}_{u \sim \pi'_h(\cdot|z)} A^{\pi}_h(z,u),$$

где $\mathrm{TV}(P,Q) = \sup_B |P(B) - Q(B)|$. Ключевое обстоятельство: $\bar{\alpha}_h$ *вычисляется по состояниям старой политики*, то есть по тем данным, на которых обновление и строится.

2.5 Алгоритм (идеализация GRPO)

На обновлении k выбираются контексты. Из каждого стартового состояния запускается группа из G независимых эпизодов с исходами $Y_i \in \{0,1\}$. Групповое преимущество

$$A_i = \frac{Y_i - \bar{Y}}{\max(\hat{\sigma}, \epsilon)}, \qquad \bar{Y} = \tfrac{1}{G}\textstyle\sum_j Y_j, \quad \hat{\sigma}^2 = \tfrac{1}{G}\textstyle\sum_j (Y_j - \bar{Y})^2, \tag{2}$$

и усечённая суррогатная функция

$$\mathcal{L}^{\text{clip}}(\theta) = \frac{1}{N}\sum_i \sum_h \min\Big(r_{ih}(\theta)A_i,\ \text{clip}\big(r_{ih}(\theta), 1-\varepsilon_-, 1+\varepsilon_+\big)A_i\Big), \quad r_{ih} = \frac{\pi_\theta(u_{ih} \mid x_{ih})}{\pi_{\theta_k}(u_{ih} \mid x_{ih})}. \tag{3}$$

Её максимизируют несколькими эпохами по мини-батчам, с энтропийным бонусом и, возможно, с якорем к эталонной политике. В конфигурации WidowX: $G = 8$, $\varepsilon_- = 0{,}2$, $\varepsilon_+ = 0{,}28$, 4 эпохи, коэффициент энтропии $2 \cdot 10^{-4}$, фильтр групп по стандартному отклонению 0,05 (динамическое сэмплирование в духе DAPO [8]). Для CDPR кредит дополнительно распределяется по вехам [1]. Оптимизатор Adam, усечение нормы градиента и разделение на мини-батчи в теории не моделируются. Их влияние входит в ошибку шага (теорема 6.4).

3 Вспомогательные утверждения

Лемма 3.1 (Разность производительностей, конечный горизонт)**.** *Для любых политик π, π' и задачи $\mathcal{T}$*

$$J(\pi') - J(\pi) = \sum_{h=0}^{H-1} \mathbb{E}_{z \sim d_h^{\pi'}} \bar{A}_h(z) = \sum_{h=0}^{H-1} \mathbb{E}_{z \sim d_h^{\pi'}} \langle \pi'_h(\cdot \mid z) - \pi_h(\cdot \mid z), Q_h^\pi(z, \cdot)\rangle.$$

Доказательство. Так как $V_H^\pi = \mathbf{1}_E$ и d_0 не зависит от политики, имеем $J(\pi') = \mathbb{E}^{\pi'} V_H^\pi(z_H)$ и $J(\pi) = \mathbb{E}^{\pi'} V_0^\pi(z_0)$. Телескопируя, $J(\pi') - J(\pi) = \sum_h \mathbb{E}^{\pi'}[V_{h+1}^\pi(z_{h+1}) - V_h^\pi(z_h)]$. Переходное ядро не зависит от политики, поэтому $\mathbb{E}[V_{h+1}^\pi(z_{h+1}) \mid z_h, u_h] = Q_h^\pi(z_h, u_h)$, и слагаемое равно $\mathbb{E}^{\pi'}[Q_h^\pi(z_h, u_h) - V_h^\pi(z_h)] = \mathbb{E}_{d_h^{\pi'}} \bar{A}_h$. Второе равенство следует из $\mathbb{E}_{u \sim \pi_h} A_h^\pi(z, u) = 0$. □

Лемма 3.2 (Сдвиг распределения состояний)**.** *Для $h = 0, \dots, H$*

$$\text{TV}\big(d_h^{\pi'}, d_h^\pi\big) \le \sum_{t<h} \bar{\alpha}_t.$$

В частности, для законов траекторий $\text{TV}(\mathbb{P}^{\pi'}, \mathbb{P}^\pi) \le \sum_{t=0}^{H-1} \bar{\alpha}_t$.

Доказательство. Пусть $K_t^\pi(z, \cdot) = \int \pi_t(du \mid z)\, T_t(\cdot \mid z, u)$ — ядро перехода $z_t \to z_{t+1}$. Тогда $d_{t+1}^{\pi'} - d_{t+1}^\pi = (d_t^{\pi'} - d_t^\pi)K_t^{\pi'} + d_t^\pi(K_t^{\pi'} - K_t^\pi)$. Марковское ядро не увеличивает расстояние по вариации, поэтому TV-норма первого слагаемого не превосходит $\text{TV}(d_t^{\pi'}, d_t^\pi)$. Для второго по неравенству обработки данных (одно и то же ядро $T_t(\cdot \mid z, \cdot)$ применяется к двум законам действий) $\|d_t^\pi(K_t^{\pi'} - K_t^\pi)\|_{\text{TV}} \le \int d_t^\pi(dz)\, \text{TV}(\pi'_t(\cdot \mid z), \pi_t(\cdot \mid z)) = \bar{\alpha}_t$. Индукция по t с $\text{TV}(d_0^{\pi'}, d_0^\pi) = 0$. Поскольку z_H — вся траектория, d_H есть закон траектории. □

Лемма 3.3 (Пинскер в среднем)**.** $\bar{\alpha}_h \le \sqrt{\tfrac{1}{2}\mathbb{E}_{z \sim d_h^\pi} \text{KL}(\pi_h(\cdot \mid z) \,\|\, \pi'_h(\cdot \mid z))}$*; то же верно для обратного направления KL.*

Доказательство. Неравенство Пинскера $\text{TV}(P, Q) \le \sqrt{\text{KL}(P\|Q)/2}$ и неравенство Йенсена для вогнутой функции $\sqrt{\cdot}$. □

Лемма 3.3 связывает теорию с журналами обучения. Средний выборочный KL на обновлении (`approx_kl_mean`) оценивает $\mathbb{E}_{d^\pi}$ KL на состояниях старой политики и тем самым даёт верхнюю оценку $\bar{\alpha}_h$.

4 Что оптимизирует GRPO при бинарной награде

При $R = \mathbf{1}_E$ целевая функция RL совпадает с метрикой задачи: $J(\pi) = \mathbb{E}_c \mathbb{P}^\pi(E \mid c)$. Суррогатной награды нет. Покажем, что GRPO в среднем поднимается по монотонному преобразованию этой вероятности.

Теорема 4.1 (Эффективная цель GRPO)**.** *Зафиксируем контекст c и положим $p_c(\theta) = \mathbb{P}^{\pi_\theta}(E \mid c) \in (0,1)$. Пусть функция правдоподобия траектории дифференцируема, а скор $Z = \sum_h \nabla_\theta \log \pi_\theta(u_h \mid x_h)$ имеет конечный второй момент (для гауссовской политики (1) с гладким средним и отделённой от нуля дисперсией на конечном горизонте это выполнено). Рассмотрим направление обновления в точке поведения $\theta = \theta_k$, где все $r_{ih} = 1$ и усечение неактивно: $g = \frac{1}{G}\sum_i A_i Z_i$.*

(a) При нормировке по генеральной совокупности, $A = (Y - p)/\sqrt{p(1-p)}$,

$$\mathbb{E}g = \frac{\nabla_\theta p_c}{\sqrt{p_c(1-p_c)}} = \nabla_\theta \big[2 \arcsin \sqrt{p_c(\theta)}\big].$$

(b) При групповой нормировке (2) $\mathbb{E}g = c_{G,\epsilon}(p_c)\nabla_\theta p_c$, где

$$c_{G,\epsilon}(p) = \frac{1}{p(1-p)}\,\mathbb{E}\Big[\frac{Q(1-Q)}{\max(\sqrt{Q(1-Q)}, \epsilon)}\Big] > 0, \qquad Q = K/G, \quad K \sim \mathrm{Bin}(G, p);$$

при $G \to \infty$ имеем $c_{G,\epsilon}(p) \to 1/\sqrt{p(1-p)}$.

(c) Для контекстов $c \sim \mathcal{D}$ с общими параметрами $\mathbb{E}g = \nabla_\theta \mathbb{E}_c F_G(p_c(\theta))$, где $F_G' = c_{G,\epsilon}$, и F_G строго возрастает на $(0,1)$.

Доказательство. Производная $\min(rA, \mathrm{clip}(r, 1-\varepsilon_-, 1+\varepsilon_+)A)$ по θ при $r = 1$ равна $A\nabla_\theta r = A\nabla_\theta \log \pi_\theta$, так как 1 — внутренняя точка интервала усечения; суммирование по h даёт AZ. (а) По тождеству скор-функции $\mathbb{E}[Z] = 0$ и $\mathbb{E}[YZ] = \nabla\mathbb{E}[Y] = \nabla p$, поэтому $\mathbb{E}[(Y-p)Z] = \nabla p$. Остаётся заметить, что $\frac{d}{dp} 2\arcsin\sqrt{p} = 1/\sqrt{p(1-p)}$. (б) Условно на метки $Y_{1:G}$ траектории независимы, поэтому $\mathbb{E}[Z_i \mid Y_{1:G}] = \mathbb{E}[Z_i \mid Y_i]$; при этом $\mathbb{E}[Z \mid Y = 1] = \nabla p/p$ и $\mathbb{E}[Z \mid Y = 0] = -\nabla p/(1-p)$. Подстановка даёт $\mathbb{E}[g \mid Y_{1:G}] = \frac{Q(1-Q)}{d(Q)}\big(\frac{1}{p} + \frac{1}{1-p}\big)\nabla p$ с $d(Q) = \max(\sqrt{Q(1-Q)}, \epsilon)$; осталось усреднить по K. Предел следует из $Q \to p$ п.н. и ограниченности подынтегрального выражения. Формула и её связь с (а) получены в [1]; см. также [9]. (в) Линейность математического ожидания; закон выбора контекстов от θ не зависит. □

Следствие 4.2 (Свойства эффективной цели)**.** *(i) Контекст с $p_c \in \{0,1\}$ не даёт вклада. В реализации вырожденная группа даёт $A_i \equiv 0$ точно, а не только в среднем.*

(ii) Относительно обычного градиента политики вес контекста равен $1/\sqrt{p(1-p)}$: трудные контексты ($p \to 0$) усиливаются как $p^{-1/2}$. Функция $2\arcsin\sqrt{p}$ вогнута на $[0, \frac{1}{2}]$ и выпукла на $[\frac{1}{2}, 1]$.

(iii) Парето-оптимальность. *Если θ^* — (локальный) максимум $\mathbb{E}_c F_G(p_c(\theta))$, то вектор $(p_c(\theta^*))_c$ (локально) Парето-оптимален: не существует θ' (в окрестности) с $p_c(\theta') \geq p_c(\theta^*)$ для $\mathcal{D}$-п.в. c и строгим неравенством на множестве положительной меры.*

Доказательство. (i) и (ii) следуют из теоремы 4.1. (iii) Если бы такое θ' существовало, строгое возрастание F_G дало бы $\mathbb{E}_c F_G(p_c(\theta')) > \mathbb{E}_c F_G(p_c(\theta^*))$, что противоречит максимальности. □

Таким образом, GRPO оптимизирует не арифметическое среднее успеха, а другую скаляризацию того же вектора вероятностей успеха по контекстам. Её оптимумы Парето-оптимальны, а если в классе есть политика, решающая все контексты, обе скаляризации достигают максимума на ней.

Замечание 4.3 (Константы реализации). Для бинарной группы размера G максимум $|A_i|$ равен $\sqrt{G-1}$ (один успех из G); при $G = 8$ это 2,65. Поэтому порог усечения преимуществ 6,0 при бинарной награде не срабатывает. Минимальное ненулевое групповое стандартное отклонение равно $\sqrt{(G-1)}/G \approx 0{,}33 > 0{,}05$, так что фильтр по стандартному отклонению удаляет ровно вырожденные группы.

Замечание 4.4 (Вехи). Для вложенных вех $E^{(1)} \supseteq \cdots \supseteq E^{(m)}$ с независимо нормированными преимуществами и весами $w_j \geq 0$ то же рассуждение даёт среднее направление $\sum_j w_j c_{G,\epsilon}(P(E^{(j)}))\nabla P(E^{(j)})$, а по цепному правилу $J = \prod_j P(E^{(j)} \mid E^{(j-1)})$. Анализ правила защиты достигнутых вех ($\kappa = 0$) дан в [1, предложение C].

5 Устойчивость: доверительная область и сохранение навыков

Теорема 5.1 (Улучшение в доверительной области для вероятности успеха)**.** *Для любых политик π, π' положим $L_\pi(\pi') = \sum_h \mathbb{E}_{d_h^\pi} \bar{A}_h$ и $\varepsilon = \sup_{h,z} |\bar{A}_h(z)|$. Тогда*

$$J(\pi') \;\geq\; J(\pi) + L_\pi(\pi') - 2\varepsilon \sum_{h=1}^{H-1} \sum_{t<h} \bar{\alpha}_t \;\geq\; J(\pi) + L_\pi(\pi') - H(H-1)\,\varepsilon \max_t \bar{\alpha}_t. \tag{4}$$

Кроме того, $\varepsilon \leq \alpha_\infty := \sup_{h,z} \alpha_h(z)$, откуда $J(\pi') \geq J(\pi) + L_\pi(\pi') - H(H-1)\alpha_\infty^2 \geq J(\pi) + L_\pi(\pi') - \frac{1}{2}H(H-1)\delta$, где $\delta = \sup_{h,z} \mathrm{KL}(\pi_h(\cdot \mid z) \| \pi'_h(\cdot \mid z))$.

Доказательство. По лемме 3.1 $J(\pi') - J(\pi) - L_\pi(\pi') = \sum_h \int \bar{A}_h \, d(d_h^{\pi'} - d_h^\pi)$. Для функции со значениями в $[-\varepsilon, \varepsilon]$ имеем $|\int f \, d(\nu - \nu')| \leq 2\varepsilon \, \mathrm{TV}(\nu, \nu')$, а по лемме 3.2 $\mathrm{TV}(d_h^{\pi'}, d_h^\pi) \leq \sum_{t<h} \bar{\alpha}_t$. Слагаемое с $h = 0$ равно нулю, и $\sum_{h=1}^{H-1} h = H(H-1)/2$. Далее, $\bar{A}_h(z) = \mathbb{E}_{\pi'_h} Q_h^\pi(z, \cdot) - \mathbb{E}_{\pi_h} Q_h^\pi(z, \cdot)$, а $Q \in [0, 1]$, поэтому $|\bar{A}_h(z)| \leq \alpha_h(z)$. Последнее неравенство — неравенство Пинскера. □

Следствие 5.2 (Монотонность шага миноризации–максимизации)**.** *Положим $M_\pi(\pi') = J(\pi) + L_\pi(\pi') - \frac{1}{2}H(H-1)\delta(\pi, \pi')$. Тогда $J(\pi') \geq M_\pi(\pi')$ и $M_\pi(\pi) = J(\pi)$. Следовательно, любое обновление с $M_{\pi_k}(\pi_{k+1}) \geq M_{\pi_k}(\pi_k)$ не уменьшает вероятность успеха: $J(\pi_{k+1}) \geq J(\pi_k)$.*

Это аналог рассуждения TRPO [4] для вероятности успеха на конечном горизонте; множитель $H(H-1)$ при α_∞^2 играет роль множителя $4\varepsilon\gamma/(1-\gamma)^2$ из дисконтированного случая (там $\varepsilon = \max |A|$), и при эффективном горизонте $1/(1-\gamma) \approx H$ оба растут как H^2. CPO-подобная форма с ожидаемой вариацией приведена в [6].

Замечание 5.3 (Как это соотносится с усечением и что из этого следует).

(i) Если бы для всех действий отношение $r = \pi'/\pi$ лежало в $[1 - \varepsilon_-, 1 + \varepsilon_+]$, то $\alpha_h(z) = \frac{1}{2}\mathbb{E}_\pi|r - 1| \leq \frac{1}{2}\max(\varepsilon_-, \varepsilon_+) = 0{,}14$. Усечение PPO этого не гарантирует: оно лишь убирает стимул выходить за полосу на *выборочных* действиях [11, 12]. Поэтому условия теоремы — свойство *реализованного* шага, и его надо контролировать по журналу (`approx_kl`, доля усечений, отбраковка шагов с большим KL).

(ii) Допустимый шаг убывает как H^{-2}: улучшение гарантировано при $\delta < 2L_\pi(\pi')/(H(H-1))$. Отсюда теоретический довод в пользу кусков действий (уменьшают H как число решений) и малых шагов на длинных задачах.

(iii) Константы худшего случая: при $H = 40$ и $\delta = 0{,}009$ штраф $\frac{1}{2}H(H-1)\delta \approx 7$ превосходит единицу, и оценка численно бессодержательна. Её значение структурное: она объясняет *почему* и *как* размер шага должен зависеть от горизонта, но не сертифицирует конкретное обновление.

Следующая теорема использует только средние по состояниям старой политики. Поэтому она проверяема по данным, и численная проверка показывает, что она почти точна (приложение A).

Теорема 5.4 (Сохранение навыка)**.** *Для любой задачи $\mathcal{T}$ и любых π, π'*

$$\left|J_{\mathcal{T}}(\pi') - J_{\mathcal{T}}(\pi)\right| \le \mathrm{TV}\big(\mathbb{P}^{\pi'}_{\mathcal{T}}, \mathbb{P}^{\pi}_{\mathcal{T}}\big) \le \Delta_{\mathcal{T}}(\pi, \pi') := \sum_{h=0}^{H-1} \mathbb{E}_{z\sim d_h^{\pi,\mathcal{T}}} \alpha_h(z) \le \sum_{h=0}^{H-1} \sqrt{\tfrac{1}{2}\mathbb{E}_{d_h^{\pi,\mathcal{T}}} \mathrm{KL}\big(\pi_h \| \pi'_h\big)}.$$

Доказательство. E — событие, поэтому $|\mathbb{P}^{\pi'}(E) - \mathbb{P}^{\pi}(E)| \le \mathrm{TV}$. Далее применяются лемма 3.2 при $h = H$ и лемма 3.3. □

Принципиально, что ожидание берётся по состояниям *данной* задачи $\mathcal{T}$ при старой политике. Обновление контролирует изменение политики только там, где оно собирает данные.

Следствие 5.5 (Смесь задач и цена исключения)**.** *Пусть обучение ведётся на смеси задач с весами $w_{\mathcal{T}} \ge 0$, $\sum w_{\mathcal{T}} = 1$, и реализованный шаг удовлетворяет $\sum_{\mathcal{T}} w_{\mathcal{T}} \Delta_{\mathcal{T}}(\pi, \pi') \le \bar{\Delta}$. Тогда для каждой задачи с $w_{\mathcal{T}} > 0$*

$$|J_{\mathcal{T}}(\pi') - J_{\mathcal{T}}(\pi)| \le \bar{\Delta}/w_{\mathcal{T}}.$$

Для задачи с $w_{\mathcal{T}} = 0$ никакой оценки не следует: её изменение определяется обобщением общей сети и не контролируется доверительной областью.

Доказательство. Все слагаемые неотрицательны, поэтому $w_{\mathcal{T}} \Delta_{\mathcal{T}} \le \bar{\Delta}$; далее применяется теорема 5.4. □

Следствие 5.6 (Накопление дрейфа)**.** *После K обновлений $|J_{\mathcal{T}}(\pi_K) - J_{\mathcal{T}}(\pi_0)| \le \sum_{k<K} \Delta_{\mathcal{T}}(\pi_k, \pi_{k+1})$. Оценка растёт линейно по K, то есть доверительная область на каждом шаге* не *ограничивает суммарную деградацию. Более того, теорема 5.1 для смесевой цели $J_w = \sum w_{\mathcal{T}} J_{\mathcal{T}}$ допускает «обмен» навыков: J_w растёт, тогда как отдельная $J_{\mathcal{T}}$ падает, причём на каждом шаге не более чем на $\bar{\Delta}/w_{\mathcal{T}}$.*

Следствие 5.7 (Якорь к эталонной политике)**.** *Пусть π_{ref} — замороженная эталонная политика и $D_{\mathrm{ref}}(\pi) = \sum_h \mathbb{E}_{z\sim d_h^{\pi_{\mathrm{ref}},\mathcal{T}}} \mathrm{KL}(\pi_{\mathrm{ref},h}(\cdot \mid z) \| \pi_h(\cdot \mid z))$. Тогда для* любой *итерации, независимо от числа шагов,*

$$|J_{\mathcal{T}}(\pi) - J_{\mathcal{T}}(\pi_{\mathrm{ref}})| \le \sqrt{H\, D_{\mathrm{ref}}(\pi)/2}.$$

Для гауссовских политик с общей ковариацией $\mathrm{KL} = \sum_j (\mu_j - \mu_{\mathrm{ref},j})^2/(2\sigma_j^2)$; именно этот член реализован в якоре (`reference_anchor.py`).

Доказательство. Применим теорему 5.4, взяв π_{ref} в роли старой политики: ожидания берутся по $d^{\pi_{\mathrm{ref}}}$. Затем применим Пинскера и неравенство Коши–Буняковского: $\sum_h \sqrt{x_h/2} \le \sqrt{H \sum_h x_h/2}$. □

В реализации банк якоря содержит не все состояния эталона, а состояния его *успешных* эпизодов. Для этого случая есть односторонняя версия.

Следствие 5.8 (Сохранение по банку успехов)**.** *Пусть q^+ — закон траекторий π_{ref} при условии успеха и $\Lambda(\pi) = \mathbb{E}_{q^+} \sum_h \log \frac{\pi_{\mathrm{ref},h}(u_h|z_h)}{\pi_h(u_h|z_h)}$. Тогда*

$$J_{\mathcal{T}}(\pi) \;\ge\; J_{\mathcal{T}}(\pi_{\mathrm{ref}})\, e^{-\Lambda(\pi)} \;\ge\; J_{\mathcal{T}}(\pi_{\mathrm{ref}})\big(1 - \Lambda(\pi)\big).$$

Для гауссовских политик с общей диагональной ковариацией $\Lambda = \sum_h \mathbb{E}_{q^+} \sum_j \Big[\frac{(\mu_j - \mu_{\mathrm{ref},j})^2}{2\sigma_j^2} + \frac{(\mu_{\mathrm{ref},j} - \mu_j)(u_j - \mu_{\mathrm{ref},j})}{\sigma_j^2}\Big]$. Первый член есть штраф якоря на банке успехов. Второй имеет первый порядок по $\|\mu - \mu_{\mathrm{ref}}\|$ и исчезает, если на состояниях банка успех не смещает латентное действие относительно среднего эталона.

Доказательство. $J(\pi) \geq \int_E d\mathbb{P}^\pi = J(\pi_{\mathrm{ref}})\mathbb{E}_{q^+}[d\mathbb{P}^\pi / d\mathbb{P}^{\pi_{\mathrm{ref}}}] \geq J(\pi_{\mathrm{ref}}) \exp(\mathbb{E}_{q^+} \log(d\mathbb{P}^\pi / d\mathbb{P}^{\pi_{\mathrm{ref}}}))$ по неравенству Йенсена. Множители динамики в отношении правдоподобий сокращаются. Формула для гауссовского случая получается раскрытием квадратов. □

6 Сходимость: консервативные шаги как неточный зеркальный спуск

Теоремы раздела 5 гарантируют, что шаг не вредит. Теперь покажем, что последовательность таких шагов *приходит* к успешной политике.

Определение 6.1 (KL-проксимальный шаг)**.** Для оценки $\hat{Q}_k$ шаг

$$\pi_{k+1,h}(\cdot \mid z) = \arg\max_q \Big\{ \mathbb{E}_{u\sim q} \hat{Q}_{k,h}(z,u) - \tfrac{1}{\eta} \mathrm{KL}\big(q \,\|\, \pi_{k,h}(\cdot \mid z)\big) \Big\} = \frac{\pi_{k,h}(\cdot \mid z)\, e^{\eta \hat{Q}_{k,h}(z,\cdot)}}{\mathbb{E}_{\pi_{k,h}} e^{\eta \hat{Q}_{k,h}(z,\cdot)}}$$

(второе равенство — вариационный принцип Гиббса) называется *KL-проксимальным*, или шагом зеркального спуска в пространстве политик.

Суррогат PPO с KL-штрафом в популяционной форме совпадает с целевой функцией этого шага при $\eta = 1/\beta$. Усечённый суррогат (3) есть его приближение первого порядка, где полоса усечения играет роль $1/\eta$ [17, 15, 14, 18]. GRPO подставляет в качестве $\hat{Q}$ монте-карловские исходы группы: $\mathbb{E}[Y \mid z_h, u_h] = Q_h^\pi(z_h, u_h)$.

Теорема 6.2 (Сходимость к любому сравнимому поведению)**.** *Пусть $\hat{Q}_k = Q^{\pi_k}$ (точные оценки) и $\tilde{\pi}$ — произвольная политика с*

$$D(\tilde{\pi}\|\pi_0) := \sum_{h=0}^{H-1} \mathbb{E}_{z\sim d_h^{\tilde{\pi}}} \mathrm{KL}\big(\tilde{\pi}_h(\cdot \mid z) \,\|\, \pi_{0,h}(\cdot \mid z)\big) < \infty.$$

Тогда для любых $\eta > 0$ и $K \geq 1$

$$\frac{1}{K} \sum_{k<K} \big[J(\tilde{\pi}) - J(\pi_k)\big] \leq \frac{D(\tilde{\pi}\|\pi_0)}{\eta K} + \frac{H\eta}{8},$$

и при $\eta = \sqrt{8D/(HK)}$

$$\min_{k<K} \big[J(\tilde{\pi}) - J(\pi_k)\big] \leq \sqrt{\frac{H\, D(\tilde{\pi}\|\pi_0)}{2K}}.$$

Доказательство. Зафиксируем (h, z) и обозначим $Q = Q_h^{\pi_k}(z, \cdot) \in [0,1]$, $Z_k = \mathbb{E}_{\pi_k} e^{\eta Q}$. Из определения шага для любого закона q

$$\mathrm{KL}(q\|\pi_{k+1}) - \mathrm{KL}(q\|\pi_k) = \mathbb{E}_q \log \frac{\pi_k}{\pi_{k+1}} = -\eta \mathbb{E}_q Q + \log Z_k.$$

По лемме Хёфдинга $\log Z_k \leq \eta \mathbb{E}_{\pi_k} Q + \eta^2/8$. При $q = \tilde{\pi}_h(\cdot \mid z)$ получаем

$$\langle \tilde{\pi}_h - \pi_{k,h}, Q_h^{\pi_k} \rangle(z) \leq \frac{\mathrm{KL}(\tilde{\pi}\|\pi_k)(z) - \mathrm{KL}(\tilde{\pi}\|\pi_{k+1})(z)}{\eta} + \frac{\eta}{8}.$$

По лемме 3.1 с $\pi' = \tilde{\pi}$ имеем $J(\tilde{\pi}) - J(\pi_k) = \sum_h \mathbb{E}_{d_h^{\tilde{\pi}}} \langle \tilde{\pi}_h - \pi_{k,h}, Q_h^{\pi_k} \rangle$. Ключевое обстоятельство: мера $d_h^{\tilde{\pi}}$ *не зависит от* k. Поэтому суммирование по $k < K$ телескопирует KL-члены в каждой точке z:

$$\sum_{k<K} \big[J(\tilde{\pi}) - J(\pi_k)\big] \leq \frac{1}{\eta} \sum_h \mathbb{E}_{d_h^{\tilde{\pi}}} \big[\mathrm{KL}(\tilde{\pi}\|\pi_0) - \mathrm{KL}(\tilde{\pi}\|\pi_K)\big] + \frac{KH\eta}{8} \leq \frac{D}{\eta} + \frac{KH\eta}{8}.$$

Минимизация по η завершает доказательство. □

Теорема не требует, чтобы сравнительная политика была оптимальной: достаточно любого успешного поведения на конечном KL-расстоянии от начальной политики. Это и есть ответ на подвопрос (У3) в идеализированной форме. Консервативные шаги не мешают сходимости, их размер (η) лишь задаёт скорость. Вся «трудность задачи» сосредоточена в одном числе D.

Следствие 6.3 (Гауссовские политики: роль приора и начального шума)**.** *Пусть* $\pi_{0,h}(\cdot \mid z) = \mathcal{N}(\mu_0(x), \sigma_0^2 I_m)$, $\tilde{\pi}_h(\cdot \mid z) = \mathcal{N}(\tilde{\mu}(x), \tilde{\sigma}^2 I_m)$. *Тогда*

$$D(\tilde{\pi}\|\pi_0) = \sum_h \mathbb{E}_{d_h^{\tilde{\pi}}} \frac{\|\tilde{\mu}(x) - \mu_0(x)\|^2}{2\sigma_0^2} + Hm\Big[\log\frac{\sigma_0}{\tilde{\sigma}} + \frac{\tilde{\sigma}^2}{2\sigma_0^2} - \frac{1}{2}\Big],$$

и для средней ошибки ϵ *достаточно* $K \geq HD/(2\epsilon^2)$ *шагов. Отсюда: (а) скорость определяется рассогласованием среднего начальной политики с успешным поведением* вдоль траекторий успешного поведения*, в единицах начального шума; (б) требуемая точность* $\tilde{\sigma} \ll \sigma_0$ *обходится лишь логарифмически; (в) нулевая инициализация остатка ставит* $\mu_0 = \tanh(p)$*, то есть приор. Если приор — постоянное смещение, далёкое от нужных действий (как на CDPR), D велико: остаток должен его компенсировать и работает в насыщении* $\tanh$.

Доказательство. Формула KL двух изотропных гауссиан и теорема 6.2. □

Например, при $\sigma_0 = e^{-1{,}2} \approx 0{,}30$ (начальное значение $\log\sigma$ в реализации) рассогласование 0,1 по одной координате стоит 0,055 нат на шаг, а 0,5 — уже 1,38 нат. Это в 25 раз больше, и при той же точности требуется в 25 раз больше обновлений. Ограниченность (1) добавляет условие представимости: среднее сравнительной политики должно лежать в $[\tanh(p - s_r), \tanh(p + s_r)]$ [1, §6].

Реальный шаг не является точным шагом Гиббса: Q оценивается по G исходам, шаг проецируется на класс сети над замороженными признаками, а усечение лишь приближает проксимальный шаг. Все эти отклонения учитывает следующая теорема.

Теорема 6.4 (Неточный шаг: оценивание, представление и покрытие)**.** *Пусть* π_k *— произвольная последовательность политик. Определим* невязку шага

$$e_{k,h}(z) = \langle \tilde{\pi}_h - \pi_{k,h}, Q_h^{\pi_k} \rangle(z) - \frac{\mathrm{KL}(\tilde{\pi}\|\pi_k)(z) - \mathrm{KL}(\tilde{\pi}\|\pi_{k+1})(z)}{\eta} - \frac{\eta}{8}$$

(для точного шага Гиббса $e_{k,h} \leq 0$*). Пусть* ν_h *— распределение состояний, на которых собираются данные шага h (по политике и из рестартов), и* $C_h = \mathbb{E}_{\nu_h}\big[(dd_h^{\tilde{\pi}}/d\nu_h)^2\big] = 1 + \chi^2(d_h^{\tilde{\pi}}\|\nu_h)$. *Тогда*

$$\frac{1}{K}\sum_{k<K}\big[J(\tilde{\pi}) - J(\pi_k)\big] \leq \frac{D(\tilde{\pi}\|\pi_0)}{\eta K} + \frac{H\eta}{8} + \frac{1}{K}\sum_{k<K}\sum_h \sqrt{C_h}\,\big\|e_{k,h}^+\big\|_{L^2(\nu_h)}.$$

Доказательство. Как в теореме 6.2, но с невязкой. По неравенству Коши–Буняковского

$$\mathbb{E}_{d_h^{\tilde{\pi}}} e_{k,h} \leq \mathbb{E}_{\nu_h}\Big[\frac{dd_h^{\tilde{\pi}}}{d\nu_h}\, e_{k,h}^+\Big] \leq \sqrt{C_h}\,\|e_{k,h}^+\|_{L^2(\nu_h)}.$$

□

Три члена оценки отвечают трём механизмам. *Оптимизационный* член $D/(\eta K) + H\eta/8$ отражает то, что консервативный шаг сходится. *Невязка* e складывается из ошибки оценивания Q по группе (на вырожденной группе оценка преимущества равна нулю, и невязка

равна полному истинному преимуществу), ошибки представления (шаг Гиббса не выразим на признаках φ) и ошибки приближения проксимального шага усечённым суррогатом. Член *покрытия* C_h показывает, насколько состояния, на которых учимся, покрывают состояния успешного поведения. Если ν_h не имеет массы там, где её имеет $d_h^{\tilde{\pi}}$, то $C_h = \infty$ и гарантии нет: алгоритм не знает, что делать в состояниях, которых не видел. Такова формальная роль стартовых распределений (объект в захвате, выровненный захват, лестница расстояний) и рестартов из промежуточных состояний [2, 13].

Замечание 6.5 (Реактивные политики). Расширенное состояние содержит время и историю, поэтому рестарт «объект в захвате» в момент 0 формально не совпадает с состоянием составной задачи в момент h. Если политика реактивна (зависит от текущего наблюдения, приора и инструкции; внутреннюю память можно включить в s), а событие успеха определяется будущим участком траектории при достаточном оставшемся горизонте, все конструкции переносятся на пространство (физическое состояние, инструкция). Тогда покрытие — свойство распределения физических состояний, и рестарты непосредственно уменьшают C_h.

Предложение 6.6 (Потолок представления)**.** *Пусть на фиксированном решающем шаге h^* успех требует $\|g(\xi) - u_{h^*}\| \le r$, где $g(\xi)$ — координаты захвата в сцене (с точностью до известного отображения), и пусть $\sup_a \mathbb{P}(\|g(\xi) - a\| \le r \mid x_{h^*}) \le \beta$ почти наверное. Тогда $J(\pi) \le \beta$ для любой $\pi \in \Pi_\varphi$, каким бы алгоритмом она ни была получена.*

Доказательство. При $\pi \in \Pi_\varphi$ действие u_{h^*} разыгрывается из $\pi(\cdot \mid x_{h^*})$ с независимой случайностью, поэтому $u_{h^*} \perp g(\xi) \mid x_{h^*}$. Следовательно, $\mathbb{P}(\|g - u\| \le r \mid x) = \int \pi(du \mid x)\mathbb{P}(\|g - u\| \le r \mid x) \le \beta$; усредняем по x. □

Следовательно, теорема 6.2 приводит RL к $J_\varphi^* = \sup_{\Pi_\varphi} J$, а не к $\sup J$ по всем политикам. Разрыв $\sup J - J_\varphi^*$ определяется *представлением*, а не алгоритмом RL, и устраняется только улучшением признаков (адаптация зрения, камера на запястье), но не увеличением бюджета RL. Важна точность признаков в момент решения: в замкнутом контуре она растёт по мере приближения к объекту.

Замечание 6.7 (Случайная проекция признаков). Визуальные токены проецируются фиксированной гауссовской матрицей в $\mathbb{R}^{512}$. По лемме Джонсона–Линденштраусса [22, 23] для любого конечного множества из N векторов попарные расстояния сохраняются с множителем $1 \pm \epsilon$ с вероятностью не меньше $1 - \delta$ при $512 \gtrsim \epsilon^{-2} \log(N/\delta)$. Поэтому липшицева политика на исходных токенах, ограниченная на это множество, задаётся $L/(1-\epsilon)$-липшицевой функцией на проекциях (по теореме Киршбрауна). Потолок J_φ^* определяется в основном самими токенами VLM, а проекция ухудшает его не более чем через искажение ϵ.

Почему обучается только исполнительная часть. В рамках изложенной теории у этого решения три причины. (1) При замороженном бэкбоне класс Π_φ фиксирован, поэтому сравнительная политика в теоремах 6.2 и 6.4 не меняется со временем. При обучении бэкбона класс сдвигается, и анализ становится анализом движущейся цели. (2) Входы (x, p) стационарны, поэтому банки самоимитации и якоря (следствия 5.7, 5.8, предложение 7.6) остаются корректными на протяжении всего запуска. (3) Геометрия доверительной области задана в пространстве *действий* (KL между политиками) и от параметризации не зависит. Голова — самый дешёвый способ перемещаться в этой геометрии, а представление остаётся отдельной, явно измеримой переменной (предложение 6.6).

7 Сигнал при разреженной награде и роль простых навыков

Лемма 7.1 (Неподвижность до первого успеха)**.** *Если на обновлении все группы вырождены (все Y_i в группе равны), то $A_i \equiv 0$, и вклад градиента политики в обновление равен нулю. Параметры меняются только регуляризаторами (энтропия, якорь), направление которых не*

зависит от сигнала успеха. При независимых контекстах число групп до первой смешанной группы имеет математическое ожидание $1/\mathbb{E}_c P_{\mathrm{mix}}(p_c, G)$*, где* $P_{\mathrm{mix}}(p, G) = 1-p^G-(1-p)^G \le Gp$*. Следовательно, ожидаемое число* эпизодов *до первого ненулевого шага не меньше* $1/\mathbb{E}_c p_c$*.*

Доказательство. При $Y_1 = \cdots = Y_G$ числитель в (2) равен нулю. Число групп до первой смешанной имеет геометрическое распределение. Неравенство $1-(1-p)^G \le Gp$ есть неравенство Бернулли. □

Предложение 7.2 (Экспоненциальный барьер составной задачи)**.** *Пусть для вех составной задачи* $\mathbb{P}^{\pi_0}(E^{(j)} \mid E^{(j-1)}) \le q < 1$ *при всех* $j = 1, \dots, m$*. Тогда* $J_c(\pi_0) \le q^m$*, и ожидаемое число эпизодов до первого ненулевого шага GRPO на составной задаче не меньше* q^{-m}*.*

Доказательство. Цепное правило $J_c = \prod_j \mathbb{P}(E^{(j)} \mid E^{(j-1)})$ и лемма 7.1. □

Модельная иллюстрация. Пусть при исследовательском шуме конечное положение захвата примерно равномерно в шаре радиуса $R = 20\,\text{см}$, а захват требует попадания в шар радиуса $r = 2\,\text{см}$ в $\mathbb{R}^3$. Тогда одно событие имеет вероятность $(r/R)^3 = 10^{-3}$, а цепочка «захват–подъём–перенос–отпускание» из четырёх таких событий — порядка 10^{-12}. В задаче «кодового замка» нижняя граница экспоненциальна для *любого* алгоритма без априорной информации [3]. Следовательно, декомпозиция на навыки не эвристика, а способ обойти неустранимый барьер.

Предложение 7.3 (Плотная награда: сигнал и мост к бинарной)**.** *(a) Если условный закон плотной отдачи* R_{dense} *при данном контексте не имеет атомов, то* $P_{\mathrm{mix}} = 1$*: каждая группа информативна.*

(b) Пусть успех содержит событие $\{\min_h d(s_h) \le r\}$*, где* d *— расстояние до цели, и* $g \ge 0$ *неубывает,* $g(r) > 0$*. Если плотная стадия добилась* $\mathbb{E}\big[\frac{1}{H}\sum_h g(d(s_h))\big] \le \bar{g}$*, то* $J \ge 1 - \bar{g}/g(r)$*. Для конечной награды* $\mathbb{E}g(d(s_H)) \le \bar{g}$ *та же оценка верна для события* $\{d(s_H) \le r\}$*.*

(c) Максимум плотной цели может иметь нулевую вероятность успеха.

Доказательство. (а) Для независимых безатомных величин $\mathbb{P}(R_1 = R_2) = 0$. (б) Если $d(s_h) > r$ при всех h, то $\frac{1}{H}\sum_h g(d(s_h)) \ge g(r)$. Остаётся применить неравенство Маркова. (в) Пусть успех есть $\{d(s_H) \le r\}$, а награда равна $-d(s_H)$. Политика A всегда заканчивает на расстоянии $r+\epsilon$: её плотная цель $-(r+\epsilon)$, а успех 0. Политика B с вероятностью $\frac{1}{2}$ попадает точно, иначе заканчивает на расстоянии $3r$: её плотная цель $-1{,}5r < -(r+\epsilon)$ при $\epsilon < r/2$, а успех $\frac{1}{2}$. □

Отсюда порядок «плотная стадия → бинарная стадия». Плотная награда даёт сигнал с нулевой стартовой вероятности успеха (п. (а)), но оптимизирует смещённую цель (п. (в)). Если она довела ожидаемое расстояние до уровня ниже радиуса успеха, то по п. (б) бинарная стадия начинается с $p_0 > 0$ и далее оптимизирует саму J (теорема 4.1). Требование «окна плотной награды шире радиуса успеха» есть требование, чтобы g различала состояния вне успеха.

Теорема 7.4 (Лестница стартовых распределений)**.** *Пусть* $\mu_0, \dots, \mu_N$ *— ступени (от лёгких стартов к целевому распределению). Переход на ступень* $j+1$ *выполняется, когда оценка успеха на ступени* j *достигает порога* P*; возврат — когда она падает ниже* $D < P$*. Допустим, что в момент перехода*

$$J_{\mu_{j+1}}(\pi) \ge J_{\mu_j}(\pi) - \Delta. \tag{5}$$

Достаточные условия: $\Delta \ge \mathrm{TV}(\mu_j, \mu_{j+1})$*, или* $\Delta \ge L_V W_1(\mu_j, \mu_{j+1})$*, если* V_0^π L_V*-липшицева по стартовому состоянию. Тогда:*

(i) *если* $P-\Delta \ge D$ (условие храповика)*, то сразу после каждого перехода успех не ниже* D *и немедленного возврата нет;*

(ii) *пока успех на новой ступени остаётся в* $[P-\Delta, P]$*, доля смешанных групп не меньше* $\min\{P_{\mathrm{mix}}(P-\Delta, G), P_{\mathrm{mix}}(P, G)\}$*, то есть сигнал не исчезает;*

(iii) *если стадия RL, начатая с успеха не ниже* s*, достигает* P *за* $T(s)$ *обновлений, то весь путь занимает не более* $N\,T(P-\Delta)$ *обновлений;*

(iv) *условие (i) точно: при* $P-\Delta < D$ *существуют допустимые ступени, после перехода на которые сразу срабатывает возврат.*

При оценке успеха по n *эпизодам с точностью* $\zeta_n = \sqrt{\log(2/\delta)/(2n)}$ *(Хёффдинг) условие принимает вид* $P-\Delta-2\zeta_n \ge D$*.*

Доказательство. Достаточные условия: $J_{\mu'} - J_\mu = \int V_0^\pi \, d(\mu' - \mu) \ge -\,\mathrm{TV}(\mu, \mu')$, так как $V \in [0,1]$, и $\ge -L_V W_1$ по двойственности Канторовича–Рубинштейна. (i) $J_{\mu_{j+1}} \ge P - \Delta \ge D$. (ii) Функция $P_{\mathrm{mix}}(\cdot, G)$ унимодальна с максимумом в $\frac{1}{2}$, поэтому минимум на отрезке достигается на конце. (iii) Суммирование по ступеням. (iv) Пример с равенством в (5). Поправка на оценивание: на событии $|\hat{J} - J| \le \zeta_n$ для обеих оценок. □

Теорема формализует правило, найденное в экспериментах CDPR (раздел 9): старые пороги 0,30/0,20 при измеренном $\Delta_{p90} = 0{,}129$ нарушают условие ($0{,}171 < 0{,}20$), новые 0,45/0,30 удовлетворяют ему ($0{,}321 \ge 0{,}30$). При $P - \Delta = 0{,}321$ и $G = 8$ имеем $P_{\mathrm{mix}} \approx 0{,}955$.

Теорема 7.5 (Композиция навыков под одной инструкцией)**.** *Пусть политика реактивна (замечание 6.5), а составная задача* $\mathcal{T}_c = (\ell_c, \mu_c, E_c)$ *состоит из этапов* $j = 1, \dots, m$ *с моментами остановки* $0 = \tau_0 < \tau_1 < \cdots < \tau_m$ *и событиями «этап* j *завершён». Для каждого этапа задан навык* $\mathcal{T}_j = (\ell_j, \mu_j, E_j)$ *с тем же событием завершения этапа. Пусть* $V_j^\ell(s)$ *— вероятность завершить этап* j *из состояния* s *при инструкции* ℓ *(при достаточном оставшемся горизонте). Обозначим:*

- $p_j = \mathbb{E}_{\mu_j} V_j^{\ell_j}$ *— качество навыка;*
- ρ_j *— закон состояния передачи* s_{τ_j} *при условии завершения этапов* $1..j$ *под инструкцией* ℓ_c*,* $\rho_0 = \mu_c$*;*
- $\Gamma_j = \sum_h \mathbb{E}_{d_h^{\pi, \mathcal{T}_j}} \mathrm{TV}\big(\pi(\cdot \mid s, \ell_c), \pi(\cdot \mid s, \ell_j)\big)$ *— разрыв переноса инструкции.*

Тогда

$$J_{\mathcal{T}_c}(\pi) = \prod_{j=1}^{m} \mathbb{E}_{\rho_{j-1}} V_j^{\ell_c} \;\ge\; \prod_{j=1}^{m} \Big(p_j - \Gamma_j - \mathrm{TV}(\rho_{j-1}, \mu_j)\Big)^+ .$$

Доказательство. По строгому марковскому свойству и реактивности условная вероятность завершить этап j при условии завершения этапов $1..j-1$ и при данном $s_{\tau_{j-1}}$ равна $V_j^{\ell_c}(s_{\tau_{j-1}})$. Поэтому $\mathbb{P}(E^{(j)}) = \mathbb{P}(E^{(j-1)})\,\mathbb{E}_{\rho_{j-1}} V_j^{\ell_c}$, откуда следует равенство. Далее, $V \in [0,1]$, поэтому $\mathbb{E}_\rho V_j^{\ell_c} \ge \mathbb{E}_{\mu_j} V_j^{\ell_c} - \mathrm{TV}(\rho, \mu_j)$. Теорема 5.4, применённая к задаче (μ_j, E_j) и паре политик $\pi(\cdot \mid \cdot, \ell_c)$, $\pi(\cdot \mid \cdot, \ell_j)$, даёт $\mathbb{E}_{\mu_j} V_j^{\ell_c} \ge p_j - \Gamma_j$. Множители неотрицательны, поэтому можно взять положительные части. □

Каждый член этой оценки соответствует механизму пайплайна и измерим.

- p_j — качество навыков; его обеспечивают стадии RL навыков.
- Γ_j — насколько политика под составной инструкцией ведёт себя так же, как под инструкцией навыка. Для гауссовской головы $\Gamma_j \le \sum_h \mathbb{E}\sqrt{\frac{1}{2}\sum_i (\mu_i(x, \ell_c) - \mu_i(x, \ell_j))^2 / \sigma_i^2}$;

это вычисляется по записанным состояниям без новых эпизодов. Переразметка собственных успехов навыков под итоговую инструкцию (composition SFT) есть прямая минимизация Γ_j. Если навык размещения обучается под самой итоговой инструкцией, $\Gamma = 0$ для этого этапа.

- $\mathrm{TV}(\rho_{j-1}, \mu_j)$ — рассогласование передачи: насколько старты навыка (например, «объект в захвате») покрывают реальные состояния после предыдущего этапа. Его можно оценить двухвыборочным классификатором.

Сравнение с предложением 7.2 показывает выигрыш декомпозиции: без навыков $J_c(\pi_0) \le q^m$, с навыками $J_c(\pi_0)$ отделена от нуля величиной, не зависящей экспоненциально от m. Например, при $\mu_1 = \mu_c$ (так что $\mathrm{TV}(\rho_0, \mu_1) = 0$), $p_1 = 0{,}5$, $\Gamma_1 = 0{,}1$, $p_2 = 0{,}7$, $\mathrm{TV}(\rho_1, \mu_2) = 0{,}3$, $\Gamma_2 = 0$ получаем $J_c \ge 0{,}16$ и $P_{\mathrm{mix}}(0{,}16, 8) \approx 0{,}75$.

Предложение 7.6 (Самоимитация как шаг улучшения)**.** *Пусть β — политика, порождающая банк успехов задачи $\mathcal{T}$, q_β^+ — закон её траекторий при условии успеха, $J_\beta > 0$. Для любой θ*

$$\log \frac{J_{\mathcal{T}}(\pi_\theta)}{J_{\mathcal{T}}(\pi_\beta)} \;\ge\; G_{\mathcal{T}}(\theta) := \mathbb{E}_{q_\beta^+} \sum_h \log \frac{\pi_\theta(u_h \mid x_h)}{\pi_\beta(u_h \mid x_h)}.$$

В частности, если подгонка по правдоподобию на собственных успехах не уменьшила популяционное правдоподобие ($G_{\mathcal{T}} \ge 0$), то $J_{\mathcal{T}}(\pi_\theta) \ge J_{\mathcal{T}}(\pi_\beta)$.

Доказательство. Аналогично следствию 5.8: $J_\theta \ge J_\beta \mathbb{E}_{q^+}[d\mathbb{P}^\theta / d\mathbb{P}^\beta]$, затем неравенство Йенсена; множители динамики сокращаются [1, §6]. □

Это шаг типа EM для RL [19, 20]. Самоимитация на собственных успехах является оператором улучшения политики, а не внешним надзором. Для гауссовской головы с фиксированной ковариацией логарифм правдоподобия есть взвешенная MSE *на латентном и*. Подгонка к усечённым или сглаженным действиям этой гарантии формально не наследует.

Следствие 7.7 (Сбалансированная самоимитация задаёт нижнюю границу каждого навыка)**.** *Пусть подгонка ведётся на смеси банков с весами $w_{\mathcal{T}} > 0$ и $\sum_{\mathcal{T}} w_{\mathcal{T}} G_{\mathcal{T}}(\theta) \ge 0$. Тогда $\sum_{\mathcal{T}} w_{\mathcal{T}} \log(J_{\theta,\mathcal{T}} / J_{\beta,\mathcal{T}}) \ge 0$, и для каждой задачи*

$$J_{\theta,\mathcal{T}} \;\ge\; J_{\beta,\mathcal{T}} \prod_{\mathcal{T}' \ne \mathcal{T}} J_{\beta,\mathcal{T}'}^{\,w_{\mathcal{T}'}/w_{\mathcal{T}}}.$$

Задача с $w_{\mathcal{T}} = 0$ нижней границы не имеет.

Доказательство. Просуммировать неравенства предложения 7.6 с весами. Затем воспользоваться тем, что $\log(J_{\theta,\mathcal{T}'} / J_{\beta,\mathcal{T}'}) \le \log(1/J_{\beta,\mathcal{T}'})$ при $J \le 1$. □

Сбалансированная самоимитация поднимается по взвешенному среднему геометрическому $\prod_{\mathcal{T}} J_{\mathcal{T}}^{w_{\mathcal{T}}}$, которое обращается в нуль при исчезновении любого навыка. Это логарифмический барьер против забывания, отсутствующий у RL на одном навыке (следствие 5.5).

8 Сводная теорема: ответ на вопрос

Теорема 8.1 (О бутстрэппинге исполнительной части VLA-политики)**.** *Рассмотрим пайплайн: (I) стадии навыков $\mathcal{T}_1, \dots, \mathcal{T}_m$ (плотная, затем бинарная награда, с самоимитацией); (II) переход к составной инструкции; (III) совместное RL на $\mathcal{T}_c$ (и, возможно, на навыках из смеси) из политики π_0^{III}. Пусть выполнены допущение 2.2 и следующие условия.*

(A1) Представимость. *Существует $\tilde\pi \in \Pi_\varphi$ с $\bar D := D(\tilde\pi \| \pi_0^{\mathrm{III}}) < \infty$.*

(A2) Сигнал. *После стадий (I)–(II) выполнено* $p_0 := \prod_j \big(p_j - \Gamma_j - \mathrm{TV}(\rho_{j-1}, \mu_j)\big)^+ > 0$ *(теорема 7.5).*

(A3) Неточность шага. $\sum_h \sqrt{C_h}\, \|e^+_{k,h}\|_{L^2(\nu_h)} \le \varepsilon_{\mathrm{upd}}$ *при всех* k *(теорема 6.4).*

Тогда:

(a) вероятность того, что группа на первом обновлении (III) содержит хотя бы один успех, не меньше p_0*, а смешанной группы — не меньше* $p_0 - \mathbb{E}_c p_c^G$*; пока шаг нулевой, политика не меняется, поэтому ожидаемое число групп до первого ненулевого шага не больше* $1/(p_0 - \mathbb{E}_c p_c^G)$*, если знаменатель положителен;*

(b) при $\eta = \sqrt{8\bar{D}/(HK)}$

$$\max_{k<K} J_{\mathcal{T}_c}(\pi_k) \;\ge\; J_{\mathcal{T}_c}(\tilde{\pi}) - \sqrt{\frac{H\bar{D}}{2K}} - \varepsilon_{\mathrm{upd}};$$

(c) для навыка с весом $w_{\mathcal{T}} > 0$ *в смеси шаг с дрейфом* $\bar{\Delta}_k$ *меняет* $J_{\mathcal{T}}$ *не более чем на* $\bar{\Delta}_k / w_{\mathcal{T}}$*; с якорём бюджета* D_{ref} *отклонение от эталона не превосходит* $\sqrt{HD_{\mathrm{ref}}/2}$ *на всех итерациях;*

(d) $J_{\mathcal{T}_c}(\tilde{\pi}) \le J^*_\varphi$*, и разрыв до* $\sup J$ *определяется представлением (предложение 6.6).*

Доказательство. (а) При случайном контексте вероятность хотя бы одного успеха в группе равна $\mathbb{E}_c[1-(1-p_c)^G] \ge \mathbb{E}_c p_c = J_{\mathcal{T}_c}(\pi_0^{\mathrm{III}}) \ge p_0$ по теореме 7.5; вычитая вероятность $\mathbb{E}_c p_c^G$ группы из одних успехов, получаем оценку для смешанной группы. До первого ненулевого шага политика неподвижна (лемма 7.1), так что группы независимы и одинаково распределены. (б) Теорема 6.4 с выбранным η; среднее не превосходит максимума. (в) Следствия 5.5 и 5.7. (г) Определение J^*_φ и $\tilde{\pi} \in \Pi_\varphi$. □

Предложение 8.2 (Необходимость сигнала)**.** *Если* $p_c(\pi_0^{\mathrm{III}}) = 0$ *для* $\mathcal{D}$*-п.в. с и регуляризация отсутствует, то* $\pi_k = \pi_0^{\mathrm{III}}$ *при всех* k*. Тогда оценка (б) верна лишь с* $\varepsilon_{\mathrm{upd}} \ge J(\tilde{\pi}) - J(\pi_0^{\mathrm{III}}) - \sqrt{H\bar{D}/(2K)}$*, то есть условие (A3) нарушается. Сигнал (A2) необходим для (A3), а простые навыки — конструктивный способ его обеспечить.*

Доказательство. Лемма 7.1: все группы вырождены почти наверное, шаг нулевой, и неравенство (б) превращается в утверждение о $\varepsilon_{\mathrm{upd}}$. □

Ответ на вопрос. Исполнительную часть VLA-политики можно обучить только консервативным RL по четырём причинам. (У1) При бинарной награде GRPO поднимается по монотонному преобразованию вероятности успеха, то есть оптимизирует саму метрику задачи (теорема 4.1). (У2) Шаг в доверительной области почти монотонен и меняет успех каждого навыка, на состояниях которого он ограничен, не более чем на сумму средних вариаций (теоремы 5.1, 5.4). (У3) Последовательность таких шагов есть неточный зеркальный спуск, сходящийся к любому успешному поведению, представимому на замороженных признаках. Цена определяется KL-расстоянием от начальной политики до этого поведения, покрытием и невязкой шага (теоремы 6.2, 6.4). (У4) Сигнал существует, только если начальная вероятность успеха отделена от нуля. Для составной задачи без декомпозиции она экспоненциально мала (предложение 7.2), а описание простых навыков тройками (инструкция, старты, предикат успеха) с плотной наградой, лестницей стартов и композицией делает её отделённой от нуля за полиномиальную цену (предложение 7.3, теоремы 7.4, 7.5).

Что дали бы демонстрации и чем пайплайн их заменяет. В сводной оценке демонстрации могут войти лишь через две величины: через $\bar{D}$ (клонирование поведения приближает π_0 к $\tilde{\pi}$) и через C_h (рестарты из состояний демонстраций обеспечивают покрытие [21]).

Пайплайн управляет $\bar{D}$ с помощью RL навыков и самоимитации на собственных успехах (предложение 7.6), а C_h — с помощью стартовых распределений навыков, доступных в симуляторе (замечание 6.5). Поэтому оценка не требует демонстраций. В этом точный математический смысл утверждения «датасет для новой структуры не обязателен». При развёртывании привилегированные старты не используются: итоговая оценка проводится из μ_c.

9 Связь с экспериментами и проверяемые предсказания

Величина теории	Механизм и диагностика	Наблюдение
P_{mix}, вырожденные группы (лемма 7.1, зам. 4.3)	динамическое сэмплирование, фильтр std 0,05; доля смешанных групп по стадиям	фильтр при бинарной награде удаляет ровно вырожденные группы
$\bar{\alpha}_h \le \sqrt{\overline{\text{KL}}/2}$ (лемма 3.3)	усечение 0,2/0,28, отбраковка расходящихся шагов; `approx_kl_mean`	CDPR, LR 10^{-5}: $\overline{\text{KL}} = 0{,}009$ на обновление, $\bar{\alpha} \le 0{,}067$
Накопление дрейфа (сл. 5.6)	сумма $\sum_k \sqrt{\overline{\text{KL}}_k/2}$ по запуску	CDPR: за 113 обновлений при малом KL на шаге потеряно удержание подъёма; «обмен» plate/bowl и захват/размещение
Якорь (сл. 5.7, 5.8)	`reference_anchor`, член $(\mu - \mu_{\text{ref}})^2/(2\sigma^2_{\text{ref}})$ на банке успехов	вдвое меньший ущерб plate/lift, но эрозия lift|grasp сохраняется: граница зависит от бюджета D_{ref} и от того, покрывает ли банк нужные состояния
$w_{\mathcal{T}} = 0$ (сл. 5.5, 7.7)	стадии RL по отдельным инструкциям; поинструкционное удержание	WidowX: подход и захват потеряны уже на стадии размещения (s3); CDPR: захват стёрт до 0, когда отсутствовал в смеси SFT
$D(\tilde{\pi}\|\pi_0)$ (сл. 6.3)	остаток над приором; насыщение tanh	CDPR: приор — постоянное смещение, остаток должен его компенсировать и насыщен
Потолок J^*_φ (пр. 6.6)	замороженные признаки; ошибка локализации против допуска	CDPR: локализация 3–5 см при допуске захвата около 2 см ограничивает захват; размещение с допуском 5,7/9,1 см устойчиво
Храповик $P - \Delta \ge D$ (т. 7.4)	пороги лестницы; Δ_{p90}	0,30/0,20: 3 из 4 семейств «застряли»; 0,45/0,30: ноль возвратов, захват выведен из нуля
Γ_j, $\text{TV}(\rho, \mu)$ (т. 7.5)	переразметка успехов под итоговую инструкцию; старты «в захвате»	CDPR: составная задача отказывает на передаче захват→отпускание; WidowX: переход composition SFT оказался неэффективным

Предсказания для эксперимента WidowX-200. Теория даёт конкретные измерения, подтверждающие или опровергающие механизм.

1. *Сигнал.* Совместное RL должно стартовать, только когда оценка $J_c(\pi_0^{\mathrm{III}})$ заметно больше нуля. Доля смешанных групп в начале (III) должна согласовываться с $\mathbb{E}_c P_{\mathrm{mix}}(p_c, 8)$.
2. *Перенос инструкции.* До и после composition SFT вычислить $\hat{\Gamma}_1$ по записанным состояниям навыка захвата (KL между средними головы при ℓ_c и ℓ_{pick}). Теорема 7.5 предсказывает: если $\hat{\Gamma}_1$ не уменьшилось, переход не поднимет J_c. Это согласуется с наблюдённой неэффективностью перехода.
3. *Передача.* Оценить $\mathrm{TV}(\rho_1, \mu_2)$ между реальными состояниями после захвата и стартами «в захвате». Большое значение предсказывает отказы на передаче независимо от качества навыка размещения.
4. *Сохранение.* Держать каждую инструкцию в смеси с $w_{\mathcal{T}} \geq w_{\min}$ или под якорём. Сообщать накопленный бюджет $\sum_k \sqrt{\mathrm{KL}_k/2}$ как верхнюю границу дрейфа и проверять, что каждая семья выше своей нижней границы (следствие 7.7).
5. *Храповик.* Для каждой лестницы проверять $P - \Delta_{p90} - 2\zeta_n \geq D$ до запуска.

10 Границы применимости

1. **Усечение не является доверительной областью.** Теоремы раздела 5 относятся к *реализованным* шагам. Выполнение их условий надо измерять, а не выводить из значения $\varepsilon_{\pm}$.
2. **Константы худшего случая.** При $H \sim 40$–128 оценки улучшения численно бессодержательны (замечание 5.3). Их роль — масштабирование и структура. Теорема 5.4 численно почти точна, но требует TV по всем шагам задачи.
3. **Неточная сходимость — разложение, а не гарантия.** Для нейросетевой политики невязка e_k теорией не ограничивается. Теорема 6.4 говорит, *куда* входят оценивание, представление и покрытие, но не доказывает, что они малы.
4. **Обучение против развёртывания.** Цель J относится к стохастической обучающей политике. Оценка CDPR использует детерминированное среднее остатка при стохастическом приоре; J_{explore} и J_{deploy} надо измерять отдельно [1].
5. **Реактивность.** Теоремы о композиции и о рестартах используют реактивность политики (замечание 6.5); память кусков действий требует её включения в состояние.
6. **Происхождение данных.** Аудит происхождения отчётного контроллера CDPR (`ral_submission/evidence/DATA_LINEAGE_AUDIT_20261029.md`) показывает, что человеческих демонстраций нет. Однако в предках есть стадии SFT на данных скриптового оракула и на эпизодах выученной политики с помощью скриптовых контроллеров. Теория объясняет, почему такие стадии помогали: они дают $p_0 > 0$ и малое $\bar{D}$. Но для результата 69,14 % утверждение «без каких-либо подготовленных данных» не подтверждается. Производственная конфигурация WidowX использует только данные, порождённые самой политикой (оракул — лишь в дымовом тесте), и потому является чистой проверкой теоремы 8.1.
7. **Атрибуция.** Лемма 3.1 восходит к [2]. Теорема 5.1 — конечногоризонтная версия рассуждения [4, 6]. Теорема 6.2 — адаптация анализа зеркального спуска в пространстве политик [14, 15, 16, 13]. Теорема 4.1(a) — известное свойство нормированного GRPO [9]; см. также [10] о смещении нормировки. Предложение 7.6 — неравенство EM-типа [19, 20]. Предложение 7.2 — вариант нижних границ «кодового замка» [3]. Собственными для данной работы являются формулировки для вероятности успеха с явными константами, следствия 5.5–5.8 и 7.7, теоремы 7.4, 7.5, 8.1 и их связь с измеримыми величинами пайплайна. Окончательную новизну надо подтвердить обзором литературы.

11 Проект положений, выносимых на защиту

1. Для эпизодических задач манипуляции с бинарным предикатом успеха групповой метод GRPO в точке поведения является несмещённым подъёмом по строго возрастающему преобразованию вероятности успеха каждого контекста. Его стационарные точки Парето-оптимальны по вектору вероятностей успеха контекстов.
2. Для вероятности успеха на конечном горизонте H получены оценки улучшения в доверительной области с константой $H(H-1)/2$ и оценка сохранения навыка через сумму средних вариаций политики на состояниях этого навыка. Из них следуют количественные условия сохранения навыков при обучении смеси инструкций, линейное накопление дрейфа при покомпонентно малых шагах и равномерная по времени граница для якоря к эталонной политике.
3. Консервативная итерация политики с групповыми монте-карловскими оценками трактуется как неточный зеркальный спуск. Для неё доказана оценка разрыва до любой сравнимой политики над замороженными признаками, разложенная на оптимизационный член $O(\sqrt{HD/K})$, член покрытия (χ^2-концентрируемость) и невязку шага.
4. Доказано, что при разреженной награде начальная вероятность успеха необходима для сигнала, и для составной задачи она экспоненциально мала по числу этапов. Спецификация навыков (инструкция, стартовое распределение, предикат успеха) вместе с плотной наградой, лестницей стартов с условием храповика $P - \Delta \geq D$ и композицией обеспечивает её нижнюю границу через качество навыков, разрыв переноса инструкции и рассогласование передачи.
5. В полученной оценке демонстрации участвуют только через KL-расстояние начальной политики до успешной и через коэффициент покрытия. Обе величины управляемы без демонстраций средствами симулятора и самоимитации, что является математическим обоснованием адаптации VLA-моделей к новым кинематическим структурам без ручного сбора данных.

A Численная проверка утверждений

Скрипт `verify_theorems.py` проверяет неравенства на случайных конечных марковских процессах с конечным горизонтом и терминальной наградой успеха. Величины J, Q, A и d_h вычисляются точно динамическим программированием. Результаты записываются в `verification_results.json`. Проверка ловит ошибки в алгебре и константах, но не сертифицирует нейросетевую политику.

Утверждение	Случаев	Результат
Лемма 3.1 (тождество)	4000	ошибка $\leq 6 \cdot 10^{-16}$
Лемма 3.2	4000	выполнено
Теорема 5.1, все три формы	4000	выполнено; наибольшее отношение «нарушение/штраф» 0,56
Теорема 5.4	4000	выполнено; наибольшее отношение $\lvert\Delta J\rvert/\Delta_{\mathcal{T}} = 0{,}987$ (почти точна)
Следствие 5.7	4000	выполнено
Теорема 6.2 (точный шаг Гиббса)	600	выполнено; наибольшее отношение разрыва к оценке 0,71
Теорема 4.1(б), $p \in \{0{,}03..0{,}8\}$, $G \in \{2, 8, 32\}$	$4 \cdot 10^5$ групп	$\lvert z\rvert \leq 2{,}26$ (Монте-Карло против формулы)
Теорема 7.5 (шаг передачи)	20000	выполнено

Запуск из каталога главы: `python3 verify_theorems.py`.

Список литературы

[1] Mathematical foundation for the RA-L paper. Рабочая заметка, `ral_submission/theory/MATHEMATICAL_FOUNDATION.md`, 2026.

[2] Kakade S., Langford J. Approximately optimal approximate reinforcement learning // ICML. 2002.

[3] Kakade S. On the sample complexity of reinforcement learning. PhD thesis, University College London, 2003.

[4] Schulman J., Levine S., Abbeel P., Jordan M., Moritz P. Trust region policy optimization // ICML. 2015.

[5] Schulman J., Wolski F., Dhariwal P., Radford A., Klimov O. Proximal policy optimization algorithms // arXiv:1707.06347. 2017.

[6] Achiam J., Held D., Tamar A., Abbeel P. Constrained policy optimization // ICML. 2017.

[7] Shao Z. et al. DeepSeekMath: Pushing the limits of mathematical reasoning in open language models // arXiv:2402.03300. 2024.

[8] Yu Q. et al. DAPO: An open-source LLM reinforcement learning system at scale // arXiv:2503.14476. 2025.

[9] Mroueh Y. Reinforcement learning with verifiable rewards: GRPO's effective loss, dynamics, and success amplification // arXiv:2503.06639. 2025.

[10] Liu Z. et al. Understanding R1-Zero-like training: A critical perspective // arXiv:2503.20783. 2025.

[11] Engstrom L. et al. Implementation matters in deep RL: A case study on PPO and TRPO // ICLR. 2020.

[12] Wang Y., He H., Tan X. Truly proximal policy optimization // UAI. 2020.

[13] Agarwal A., Kakade S., Lee J., Mahajan G. On the theory of policy gradient methods: Optimality, approximation, and distribution shift // JMLR. 2021. Vol. 22, no. 98.

[14] Shani L., Efroni Y., Mannor S. Adaptive trust region policy optimization: Global convergence and faster rates for regularized MDPs // AAAI. 2020.

[15] Lan G. Policy mirror descent for reinforcement learning: Linear convergence, new sampling complexity, and generalized problem classes // Mathematical Programming. 2023. Vol. 198.

[16] Xiao L. On the convergence rates of policy gradient methods // JMLR. 2022. Vol. 23.

[17] Tomar M., Shani L., Efroni Y., Ghavamzadeh M. Mirror descent policy optimization // ICLR. 2022.

[18] Liu B., Cai Q., Yang Z., Wang Z. Neural trust region/proximal policy optimization attains globally optimal policy // NeurIPS. 2019.

[19] Dayan P., Hinton G. Using expectation-maximization for reinforcement learning // Neural Computation. 1997. Vol. 9, no. 2.

[20] Peters J., Schaal S. Reinforcement learning by reward-weighted regression for operational space control // ICML. 2007.

[21] Salimans T., Chen R. Learning Montezuma's Revenge from a single demonstration // arXiv:1812.03381. 2018.

[22] Johnson W., Lindenstrauss J. Extensions of Lipschitz mappings into a Hilbert space // Contemporary Mathematics. 1984. Vol. 26.

[23] Dasgupta S., Gupta A. An elementary proof of a theorem of Johnson and Lindenstrauss // Random Structures & Algorithms. 2003. Vol. 22, no. 1.

[24] Shukor M. et al. SmolVLA: A vision-language-action model for affordable and efficient robotics // arXiv:2506.01844. 2025.